

Pontificia Universidad Católica de Chile

Magíster en Ciencia de Datos

Actividad Final de Graduación III

Detección no supervisada de anomalías en la contratación pública de Costa Rica

Análisis de las ofertas registradas en SICOP, 2020–2025

Informe final de graduación

Federico Chan

Kenneth Díaz

Julio de 2026

Resumen

La revisión exhaustiva de ofertas es difícil de sostener cuando el volumen de transacciones supera la capacidad de inspección de los órganos de control. Este trabajo estudia si un método no supervisado puede ordenar las ofertas del Sistema Integrado de Compras Públicas de Costa Rica (SICOP) según su grado de atipicidad. Se consolidaron 3 021 336 ofertas presentadas entre 2020 y 2025 por 20 104 proveedores a 438 instituciones. La unidad de análisis es la oferta asociada a un ítem y las comparaciones se realizan dentro de categorías de la taxonomía UNSPSC.

El detector principal es Isolation Forest. La arquitectura combina 57 modelos por segmento de producto con 656 modelos por clase cuando existe suficiente soporte muestral. Su estabilidad se evaluó frente al umbral, la semilla aleatoria y la regla utilizada para combinar ambos niveles. También se comparó con tres reglas heurísticas, con HBOS y ECOD, y con una evaluación temporal en la que el período 2020–2023 se utilizó para entrenamiento y 2024–2025 para prueba. Las explicaciones locales se obtuvieron mediante SHAP.

Al seleccionar el 5 % de puntajes más extremos se identificaron 151 067 ofertas. De ellas, 108 231 aparecieron en las cinco corridas con semillas distintas; el Jaccard medio entre corridas fue 0.741. El 46 % no coincidió con ninguna de las tres reglas heurísticas. La concordancia entre algoritmos fue baja (Jaccard de 0.088 a 0.217), aunque 17 526 ofertas fueron señaladas simultáneamente por Isolation Forest, HBOS y ECOD. La evaluación temporal mostró un cambio de distribución: con el umbral fijado en entrenamiento, la tasa de alertas aumentó a 10.2 % en 2024–2025 y el Jaccard frente al modelo completo fue 0.371. Los resultados respaldan el uso del modelo como mecanismo de priorización, no como evidencia de irregularidad.

Palabras clave: detección de anomalías; aprendizaje no supervisado; contratación pública; Isolation Forest; SICOP; explicabilidad.

Índice

1. Introducción	1
2. Problema, alcance y objetivos	1
3. Trabajos relacionados	2
3.1. Marco de análisis e indicadores de riesgo	2
3.2. Detección de anomalías: supuestos y escalabilidad	3
3.3. Aprendizaje no supervisado en compras públicas	3
3.4. Enfoques relacionales, antecedentes costarricenses y síntesis	4
4. Datos y metodología	5
4.1. Origen, unidad de análisis y calidad de los datos	5
4.2. Exploración e ingeniería de variables	8
4.3. Modelo y arquitectura	10
4.4. Explicabilidad, diseño de evaluación y reproducibilidad	11
5. Resultados	12
5.1. Conjunto priorizado y perfil estadístico	13
5.2. Estabilidad interna y heterogeneidad	14
5.3. Explicaciones SHAP	16
5.4. Reglas heurísticas, algoritmos alternativos y tiempo	17
6. Discusión	19
6.1. Alcance de la evidencia	19
6.2. Relación con antecedentes y factores de confusión	20
6.3. Aplicabilidad e implicaciones para la gestión pública	21
7. Conclusiones	22
8. Consideraciones éticas	23
9. Trabajo futuro	24
A. Anexos: resultados complementarios	26
B. Anexo: repositorio de archivos reproducibles	27

1. Introducción

La contratación pública tiene un peso económico suficiente para que pequeñas mejoras en su supervisión produzcan efectos relevantes. En Costa Rica representó el 6.5 % del producto interno bruto en 2021, mientras que el promedio de América Latina y el Caribe fue estimado en 8.6 % del PIB para 2016 (OCDE, 2023; Izquierdo et al., 2018). Las cifras no son directamente comparables por corresponder a años y metodologías distintas, pero muestran la escala de la actividad. En el ámbito costarricense, SICOP concentra la publicación y tramitación electrónica de los procedimientos y su uso se volvió obligatorio con la entrada en vigencia de la Ley General de Contratación Pública en diciembre de 2022 (Poder Legislativo de Costa Rica, 2020; RACSA y Ministerio de Hacienda, 2025).

La disponibilidad de datos abiertos no elimina la restricción de capacidad. Entre 2020 y 2025, los archivos analizados contienen más de 198 mil procedimientos y 3.02 millones de ofertas. La revisión manual completa no es una alternativa realista y las reglas binarias tradicionales, aunque transparentes, pueden producir listas extensas o perder combinaciones poco frecuentes de señales (OCDE, 2016; Fazekas et al., 2016). El problema es ordenar observaciones para que la revisión especializada comience por los casos estadísticamente menos habituales ya que no se cuenta con etiquetas confiables de si la oferta fue o no fraudulenta.

La pregunta de investigación es la siguiente: ¿en qué medida un enfoque no supervisado, organizado por categorías de producto, permite identificar y priorizar ofertas atípicas en SICOP durante 2020–2025 de forma estable, interpretable y operativamente manejable? La respuesta se construye a partir de una arquitectura jerárquica de Isolation Forest, pruebas de sensibilidad, explicaciones SHAP, comparación con reglas heurísticas y algoritmos alternativos, y una evaluación temporal fuera de muestra.

El aporte es empírico y metodológico. En el plano empírico, se analiza el universo disponible a nivel oferta–ítem para seis años y se documentan patrones de precio, competencia y temporalidad. En el plano metodológico, la comparación se restringe a mercados de producto razonablemente homogéneos y se distingue entre estabilidad interna, acuerdo entre métodos y generalización temporal. Esta separación evita interpretar como validación lo que solo constituye consistencia del algoritmo.

2. Problema, alcance y objetivos

Una oferta puede ser poco frecuente por múltiples razones: un precio distante del estimado, una ventana temporal inusual, baja competencia, características particulares del procedimiento o una combinación de estas condiciones. Ninguna de ellas demuestra por sí sola una conducta irregular. En ausencia de etiquetas confirmadas, el objeto estadístico es un puntaje continuo $s(x_i)$ que ordena cada oferta x_i respecto de otras observaciones comparables. Un umbral posterior transforma ese orden en una lista de revisión, pero no cambia la naturaleza descriptiva de la señal.

La unidad de análisis es la oferta presentada por un proveedor para un ítem de un cartel. El estudio cubre registros publicados entre el 1 de enero de 2020 y el 31 de diciembre de 2025; no incluye monitoreo en tiempo real ni validación jurídica de casos. Para preservar una lectura prospectiva, el vector de entrada utiliza solo información determinada al presentar la oferta. La adjudicación y las variables del contrato firmado se conservan exclusivamente para análisis posterior y nunca ingresan al entrenamiento. Esta es la única delimitación temporal aplicada a las variables.

El objetivo general es desarrollar y evaluar una metodología no supervisada para priorizar ofertas estadísticamente atípicas en SICOP. De este objetivo se desprenden cinco objetivos específicos:

1. Caracterizar las distribuciones económicas, competitivas, temporales y de producto que condicionan el análisis.
2. Construir una base a nivel oferta–ítem con controles explícitos de calidad.
3. Implementar un detector que compare observaciones dentro de categorías homogéneas.

4. Evaluar su sensibilidad a decisiones de modelado y a cambios temporales.
5. Interpretar las señales y contrastarlas con referencias heurísticas y algorítmicas.

La ausencia de etiquetas impide reportar precisión, sensibilidad o AUC. Por ello se consideran tres tipos de evidencia. La estabilidad interna se mide con Jaccard entre semillas, umbrales y reglas de agregación. La coherencia externa se examina mediante perfiles descriptivos, tamaños de efecto, reglas de riesgo y métodos alternativos. La generalización se estudia con una separación temporal. Estas medidas responden a preguntas distintas y no deben combinarse en una única afirmación de validez.

3. Trabajos relacionados

3.1. Marco de análisis e indicadores de riesgo

La literatura pertinente no forma un único campo homogéneo. Conviven trabajos orientados a medir riesgos institucionales, estudios sobre precios anormalmente altos o bajos, detectores no supervisados de transacciones y modelos relacionales que buscan patrones entre compradores y proveedores. Compararlos únicamente por el algoritmo sería insuficiente, porque difieren en la unidad de análisis, el momento de observación y el tipo de conclusión que permiten. Por esta razón, la revisión se organiza según cuatro preguntas: qué observación recibe el puntaje; qué información utiliza el método; cómo se evalúa cuando no existe una etiqueta de referencia; y si el resultado se interpreta como señal de riesgo, anomalía estadística o predicción de una conducta.

Esta distinción es especialmente importante en contratación pública. Un contrato adjudicado resume un resultado final, mientras que una oferta registra una alternativa considerada dentro del procedimiento. Las variables disponibles después de adjudicar pueden ser útiles para estudiar resultados institucionales, pero no son equivalentes a las que tendría un analista cuando recibe la propuesta. Del mismo modo, una relación persistente entre institución y proveedor puede ser informativa a nivel de red aunque ninguna oferta individual sea extrema. El presente trabajo se sitúa deliberadamente en el nivel oferta-ítem y, por ello, utiliza la literatura de contratos y grafos como contexto y contraste, no como diseños directamente intercambiables.

Las primeras aproximaciones cuantitativas a la contratación pública suelen partir de indicadores observables y auditables. La OCDE reúne señales como la baja competencia, plazos restrictivos o patrones inusuales de adjudicación (OCDE, 2016). Fazekas et al. (2016) construyen un índice de riesgo de corrupción a partir de registros húngaros y relacionan restricciones competitivas con adjudicaciones recurrentes. Su contribución principal es convertir señales institucionales en medidas reproducibles; su limitación es que la calidad del índice depende de la disponibilidad y comparabilidad de los campos administrativos.

Fazekas y Kocsis (2020) extienden esa lógica a 2.8 millones de contratos de 28 países europeos. El uso de oferente único y de un índice compuesto permite comparaciones entre países, pero opera principalmente a nivel de contrato y bajo un marco normativo relativamente común. En un contexto distinto, las definiciones y umbrales no pueden trasladarse sin verificar cómo se registran los procedimientos. Por esa razón, en este trabajo las reglas se utilizan como referencia mínima y no como verdad de terreno.

Conti y Naldi (2008) estudian ofertas anormalmente bajas mediante un criterio basado en el promedio de las propuestas. Sus simulaciones muestran que la probabilidad de detección y de falsa alarma cambia con el número de oferentes y la dispersión de precios. Este resultado es relevante para SICOP: una regla de precio idéntica para todos los ítems ignoraría que la estructura competitiva varía de forma marcada entre mercados.

Los indicadores tienen ventajas claras para la gestión pública. Su definición puede explicarse sin reconstruir un modelo complejo, su cálculo suele ser barato y la institución puede vincular cada alerta con una disposición normativa o una hipótesis de riesgo. También facilitan el seguimiento temporal

cuando los campos administrativos mantienen significados estables. Sin embargo, una regla aislada examina una dimensión por vez y un índice compuesto requiere decidir anticipadamente la dirección y el peso de cada señal. Esas decisiones pueden ocultar combinaciones infrecuentes que no cruzan ningún umbral individual.

La diferencia entre indicador y etiqueta merece énfasis. El oferente único, un plazo corto o una razón elevada entre oferta y estimación son condiciones observables; no son confirmaciones de una infracción. Si estas reglas se emplearan para etiquetar los datos y luego se evaluara un modelo con las mismas variables, la comparación premiaría la reproducción de la regla. En este estudio se evita esa circularidad: las heurísticas se conservan como líneas de referencia transparentes y se cuantifica cuánto de la lista del modelo coincide con ellas, sin considerar el acuerdo como exactitud.

3.2. Detección de anomalías: supuestos y escalabilidad

Los detectores no supervisados formalizan la rareza de maneras diferentes. Local Outlier Factor compara la densidad local de una observación con la de sus vecinos y resulta adecuado cuando existen regiones con densidades distintas (Breunig et al., 2000). Su costo de vecindad y su sensibilidad a la métrica plantean dificultades en espacios de muchas variables y conjuntos con millones de filas. HBOS construye histogramas univariados y agrega la evidencia de rareza bajo una aproximación de independencia (Goldstein y Dengel, 2012). Su velocidad lo convierte en una referencia útil, aunque las anomalías que dependen de interacciones pueden pasar inadvertidas.

ECOD estima la posición de cada observación en las colas de distribuciones empíricas y combina señales marginales sin requerir parámetros de distribución (Li et al., 2022). Este enfoque reduce supuestos paramétricos y escala bien, pero su noción de extremidad continúa apoyándose en el comportamiento de cada dimensión. Isolation Forest adopta una geometría diferente: estima la facilidad con la que una observación queda aislada mediante particiones aleatorias (Liu et al., 2008, 2012). Una trayectoria corta indica que pocos cortes fueron suficientes para separarla de la población de referencia.

Ninguna de estas definiciones domina universalmente. Una observación puede encontrarse en una cola marginal y no ser fácil de aislar de forma multivariada; también puede pertenecer a una región local poco densa sin ocupar los extremos globales. Por ello, el desacuerdo entre métodos contiene información sobre la estructura de los datos. La comparación apropiada no consiste en proclamar ganador al algoritmo que produzca una lista intuitiva, sino en documentar qué tan sensibles son las prioridades a una definición alternativa de rareza y qué casos persisten bajo varias definiciones.

La escalabilidad no se limita al tiempo de cómputo. Un método aplicable a SICOP debe producir puntajes trazables para cada fila, permitir actualizaciones periódicas, conservar las reglas de transformación y manejar categorías con tamaños muy distintos. Isolation Forest ofrece un equilibrio favorable para esos requisitos, pero no resuelve por sí solo la elección de la población de referencia. Entrenar un único modelo global confundiría diferencias legítimas entre tipos de compra; entrenar un modelo para cada código muy específico produciría estimaciones inestables en mercados pequeños. La arquitectura jerárquica propuesta responde a ese compromiso.

3.3. Aprendizaje no supervisado en compras públicas

Domingos et al. (2016) aplican autoencoders a compras de tecnologías de información del gobierno federal brasileño. El error de reconstrucción se utiliza para ordenar transacciones y apoyar la priorización de revisiones. El estudio demuestra la viabilidad operativa de un detector no supervisado, aunque se concentra en una familia de compras y la interpretación del espacio latente es limitada.

Araújo et al. (2024) comparan Isolation Forest, Local Outlier Factor y One-Class SVM en propuestas de contratación del estado brasileño de Paraíba. Su evaluación utiliza anomalías definidas mediante inspección de valores extremos y una separación temporal 70/30. El trabajo ofrece una comparación directa

de algoritmos, pero sus etiquetas dependen de una construcción manual basada en las mismas variables observadas; por tanto, el desempeño mide cercanía a esa definición y no confirmación independiente de irregularidad.

Isolation Forest aísla observaciones mediante particiones aleatorias y asigna trayectorias más cortas a los puntos que requieren menos cortes para separarse (Liu et al., 2008, 2012). Su costo y su capacidad para operar sin supuestos distributivos fuertes lo hacen adecuado para conjuntos voluminosos. No obstante, el resultado depende del preprocesamiento, de las variables incluidas y de la población de referencia. En este proyecto esas decisiones se tratan como parte del modelo, no como pasos neutros.

Los dos antecedentes brasileños muestran posibilidades complementarias. El autoencoder de Domingos et al. (2016) aprende una representación no lineal y usa el error de reconstrucción como señal, lo que permite modelar combinaciones complejas. A cambio, la explicación de una alerta exige examinar cómo múltiples entradas afectaron la reconstrucción. El estudio de Araújo et al. (2024) compara varios detectores sobre propuestas y aproxima la evaluación mediante extremos revisados. Ese diseño es práctico cuando no hay etiquetas oficiales, pero también ilustra la dificultad central del área: una etiqueta construida con las propias variables no es independiente del fenómeno que el algoritmo intenta recuperar.

En comparación con esos trabajos, esta investigación amplía tres dimensiones que suelen tratarse por separado. Primero, la referencia se define jerárquicamente con una taxonomía de productos. Segundo, la robustez distingue semilla, umbral, agregación y tiempo, en lugar de resumirse en una única partición. Tercero, las explicaciones locales se agregan por familias para evitar presentar transformaciones correlacionadas como causas distintas. Estas diferencias no aseguran un detector más exacto; hacen más explícitas las decisiones que condicionan la lista.

3.4. Enfoques relacionales, antecedentes costarricenses y síntesis

Velasco et al. (2021) desarrollan un sistema de apoyo para investigaciones de contratación pública en Brasil que combina grafos, agrupamiento y regresión. Su unidad de interés son empresas y relaciones de riesgo, no ofertas aisladas. Potin et al. (2023) proponen PANG, un marco supervisado que representa grafos mediante patrones frecuentes y aprovecha vínculos entre contratos y actores cuando faltan atributos tabulares. Ambos trabajos muestran que la estructura relacional aporta información que un modelo oferta-ítem no observa.

Para Costa Rica, Herrera Murillo et al. (2023) analizan 103 617 procedimientos de SICOP entre 2011 y 2020 mediante redes sociales. El estudio evidencia la utilidad de representar instituciones, proveedores y contratos como un grafo y constituye el antecedente nacional más próximo. El presente análisis no reemplaza esa perspectiva: estudia una granularidad distinta y cubre un período posterior. La brecha abordada es, por tanto, acotada: detección no supervisada a nivel oferta-ítem sobre 2020–2025, con evaluación explícita de estabilidad, explicabilidad y cambio temporal.

Los enfoques relacionales pueden revelar concentración, intermediación o comunidades persistentes que no aparecen en una fila tabular. Su principal costo metodológico es que la definición del grafo incorpora decisiones sobre nodos, aristas, ventanas de tiempo y ponderaciones. Además, una relación frecuente puede reflejar especialización legítima cuando existen pocos proveedores capacitados. Por eso, los puntajes de red y de oferta deberían considerarse capas complementarias. Una eventual integración puede elevar la prioridad cuando una oferta atípica coincide con una estructura relacional inusual, pero debe conservar ambas explicaciones por separado.

El cuadro 1 resume una brecha que es metodológica antes que algorítmica. En ausencia de una verdad de terreno, el valor de un detector depende de la claridad con que define su unidad, su población comparable, su estabilidad y su uso operativo. La contribución buscada no es sustituir indicadores ni análisis de redes, sino establecer una capa de priorización a nivel oferta-ítem que pueda auditarse y combinarse posteriormente con esas fuentes.

Cuadro 1. Comparación conceptual de enfoques relevantes

Enfoque	Unidad habitual	Fortaleza principal	Restricción para este estudio
Indicadores institucionales	Contrato o procedimiento	Transparencia y vínculo con hipótesis de riesgo	Umbrales rígidos y cobertura desigual de campos
Precios anómalos	Oferta dentro de una licitación	Comparación económica directa	Dependencia del número de oferentes y de la dispersión
Detectores multivariados	Transacción u oferta	Identificación de combinaciones no anticipadas	Rareza no equivale a irregularidad
Modelos relacionales	Proveedor, institución o contrato	Representación de vínculos persistentes	No describe por sí solo por qué una oferta es extrema

La revisión también determina los límites de la comparación internacional. Los trabajos europeos y brasileños son referencias sobre diseños y señales, pero los campos, las modalidades y las reglas de SICOP pertenecen al marco costarricense. Por ello no se importan tasas esperadas de anomalías ni pesos de índices publicados. Las únicas cantidades utilizadas para fijar la cola de revisión provienen de una decisión de capacidad local; las tasas de otros estudios sirven para contextualizar métodos, no para validar resultados.

4. Datos y metodología

4.1. Origen, unidad de análisis y calidad de los datos

Los datos proceden del portal abierto de SICOP (RACSA y Ministerio de Hacienda, 2025). Doce archivos semestrales se cargaron en BigQuery, se estandarizaron mediante vistas SQL y se consolidaron en una tabla analítica. Cada fila representa la oferta de un proveedor para una línea de un cartel. El resultado contiene 3 021 336 filas, 20 104 proveedores y 438 instituciones, distribuidos en 57 segmentos y 2 196 clases UNSPSC (UNSPSC, 2024).

La construcción requirió armonizar archivos cuya estructura y nomenclatura cambiaron durante el período. El flujo separó cuatro capas: archivos de origen sin modificación, tablas de carga, vistas estandarizadas y tabla analítica. Esta separación permite reconstruir cada valor y evita que una corrección aplicada para modelar altere el registro original. Las llaves técnicas se formaron con identificadores de procedimiento, cartel, línea, proveedor y oferta; los conteos de competencia se calcularon después de consolidar esas llaves para no contar dos veces una misma participación.




Figura 1. Arquitectura de procesamiento, modelado y generación de resultados.

La figura 1 muestra el recorrido completo de los datos y las herramientas utilizadas. La estandarización y las uniones se realizan en BigQuery mediante SQL; Python y pandas construyen las características; scikit-learn implementa la arquitectura jerárquica de Isolation Forest; pyod proporciona HBOS y ECOD como contrastes; y SHAP produce las explicaciones. Esta separación permite repetir una etapa sin alterar las anteriores.

La fecha de presentación delimita el momento de observación. Las características del cartel, el tipo de procedimiento, la institución, el código de producto y el precio estimado ya existen antes o al recibir la oferta. En cambio, la adjudicación, el contrato, las modificaciones y los pagos son resultados posteriores. Estos últimos campos pueden utilizarse para describir qué ocurrió con una alerta, pero se excluyeron del vector de entrenamiento para que el puntaje pueda reproducirse en un escenario de priorización temprana.




Figura 2. Modelo lógico de las entidades y llaves utilizadas para construir la unidad oferta-ítem. Las relaciones corresponden a las uniones implementadas en la tabla analítica.

El modelo lógico de la figura 2 distingue el encabezado del procedimiento y cartel, las líneas solicitadas, el encabezado de la oferta y sus líneas. La unión principal vincula NRO_SICOP, NRO_OFERTA y NRO_LINEA; proveedor e institución se incorporan por sus cédulas y la jerarquía UNSPSC se deriva del código de producto. Los contratos no se usan como parte de los modelos para detección de anomalías, pues corresponden a información ex ante.

Los identificadores y nombres se conservaron para trazabilidad operativa, pero no ingresaron al modelo. Las variables textuales tampoco se utilizaron. La cobertura previa a diciembre de 2022 puede ser desigual porque SICOP aún no era obligatorio para todo el sector público; además, el precio estimado puede ser impreciso en servicios complejos. Estas restricciones afectan la población de referencia y se retoman en la discusión.

Los controles del cuadro 2 y la figura 3 se complementaron con validaciones de dominio. La secuencia entre presentación y cierre fue válida en 3 015 915 filas; 4 452 tenían alguna fecha incompleta y 969 registraban una presentación posterior al cierre. Estas últimas no se corrigieron sin respaldo documental: se conservaron como inconsistencias observables que pueden influir en la señal temporal. También se verificó que la cantidad de oferentes no excediera la cantidad de ofertas y que los códigos UNSPSC tuvieran longitud y nivel reconocibles. Los valores extremos no se eliminaron por regla general, porque son parte del objeto de estudio. Solo se corrigieron problemas con una explicación técnica reproducible, como tipos incompatibles o duplicados generados por una unión.

En este caso la imputación tiene un efecto distinto de la depuración. Sustituir un faltante por la mediana no afirma que ese fuera su valor real; permite que la observación reciba un puntaje y, cuando el campo es relevante, se acompaña de un indicador de disponibilidad. La mediana se estimó dentro del segmento para mantener una escala de referencia más cercana. Aun así, una categoría con faltantes sistemáticos puede modificar la geometría del modelo, por lo que la tasa de ausencia forma parte del

Cuadro 2. Controles principales de calidad de la base analítica

Control	Resultado	Tratamiento
Duplicados por llave	0	Deduplicación durante la construcción de la base
Precio ofertado nulo	886 (0.029 %)	Imputación con la mediana del segmento
Precio estimado nulo	4 325 (0.143 %)	Imputación e indicador de disponibilidad
Valores monetarios negativos	0	No se requirió corrección
Precio igual a cero	12 271 (0.41 %)	Conservado por corresponder también a muestras o cortesías
Fechas de presentación o cierre incompletas	4 452 (0.147 %)	Imputación de la variable temporal derivada
Presentación posterior al cierre	969 (0.032 %)	Conservada como inconsistencia observable




Figura 3. Evidencia agregada de los controles de integridad, completitud y secuencia temporal ejecutados sobre la base analítica. Los conteos se generan directamente desde la misma tabla utilizada por el modelo.

monitoreo recomendado.

El universo analítico incluye ofertas, no solo procedimientos adjudicados. Esta elección conserva alternativas que fueron presentadas pero no seleccionadas y permite estudiar competencia dentro del ítem. También implica que un mismo proveedor puede aparecer muchas veces y que las filas no son observaciones independientes en sentido inferencial. Las pruebas de distribución se utilizan para describir separación, no para estimar un efecto causal bajo independencia.

La granularidad oferta-ítem evita mezclar líneas diferentes de un mismo cartel, pero exige interpretar el precio unitario junto con cantidad, moneda y estimación institucional. Los archivos estandarizados convierten importes a colones cuando existe el factor correspondiente y mantienen variables que identifican el contexto monetario. Las comparaciones de escala absoluta se transforman y se realizan dentro de mercados de producto; la razón frente al estimado proporciona una medida relativa, pero solo cuando el estimado está disponible y es económicamente comparable.

UNSPSC organiza los productos y servicios de categorías generales a categorías específicas (UNSPSC, 2024). El nivel de segmento permite una mayor cobertura y un tamaño muestral más amplio, mientras que el nivel de clase mejora la homogeneidad de las observaciones. Por ello, la arquitectura final combina ambos niveles para construir dos referencias claramente diferenciadas. Sin embargo, la clase no debe interpretarse como un mercado económico perfectamente delimitado, sino como una aproximación administrativa que reduce la heterogeneidad sin considerar todo el contenido del cartel.

4.2. Exploración e ingeniería de variables

El análisis exploratorio se utilizó para decidir la transformación y el nivel de comparación. El precio ofertado presenta una mediana de 15 820 colones y una media de 20.1 millones, con valores que abarcan más de trece órdenes de magnitud. La asimetría justificó transformaciones logarítmicas. El coeficiente de variación también cambia entre segmentos, desde 0.32 en mercados relativamente homogéneos hasta valores superiores a 4 en servicios de construcción. Una única distribución global habría confundido diferencias de escala entre bienes no comparables.




Figura 4. Distribución del precio unitario ofertado y heterogeneidad de escala entre los doce segmentos UNSPSC con mayor número de observaciones.

La figura 4 respalda visualmente las dos decisiones principales del análisis exploratorio: transformar las escalas monetarias y evitar una referencia global. El panel de precios muestra una distribución fuertemente asimétrica aun después de considerar únicamente valores positivos; el panel por segmento muestra diferencias tanto en mediana como en amplitud intercuartílica.

La competencia requiere distinguir unidades. El 31.2 % de los ítems recibió una sola oferta; al contar ofertas individuales, el indicador de oferente único representa 12.7 % de las filas. Esta segunda

proporción es la comparable con el 22.2 % observado dentro del conjunto anómalo y con el 12.1 % de las ofertas normales. La aparente contradicción entre 31.2 % y 22.2 % desaparece al reconocer que la primera cifra tiene ítems como denominador y las otras dos tienen ofertas.

El vector final contiene 50 variables numéricas agrupadas en precio relativo y absoluto, cantidad, competencia, temporalidad, tipo y modalidad del procedimiento, tamaño del proveedor, régimen regulatorio y componentes de costo. Las variables monetarias se transformaron con logaritmo cuando correspondía; las categóricas se codificaron mediante indicadores; y los faltantes numéricos se imputaron con medianas.

Cuadro 3. Familias de variables utilizadas por el detector

Familia	Ejemplos	Función analítica
Precio y cantidad	precio unitario, log-precio, ratio oferta/estimado, cantidad	Capturar escala y distancia respecto de una referencia institucional
Competencia	ofertas, oferentes, oferente único, dispersión de precios	Describir la estructura observable del ítem
Temporalidad	días hasta cierre, año, mes, presentación cercana al cierre	Representar ventanas y cambios de período
Procedimiento	modalidad, tipo y régimen normativo	Ajustar diferencias administrativas observables
Proveedor	categoría de tamaño declarada	Contextualizar el tipo de participante
Producto y costos	nivel UNSPSC y componentes declarados	Mantener comparabilidad económica y composición

Las transformaciones se definieron antes de revisar la lista final. Para valores no negativos se usó el logaritmo de $1 + x$, lo que conserva ceros y reduce la influencia de escalas extremas. Los ratios con denominador nulo o igual a cero se trataron como faltantes para evitar valores infinitos; los campos originales permanecieron disponibles para auditoría. Los conteos no se estandarizaron de manera global porque los árboles no requieren una métrica euclidiana, aunque se normalizaron los puntajes antes de combinar niveles.

La categoría de tamaño del proveedor se codificó ordinalmente como microemprendedor, pequeña, mediana o grande; los registros no clasificados se imputaron junto con los demás faltantes. Esta variable describe la clasificación registrada y no un historial calculado con participaciones futuras. Los indicadores de calendario, por su parte, describen el momento de presentación. La separación entre campos originales y variables derivadas se conservó en el diccionario de datos.

Existe redundancia deliberada entre algunas transformaciones. En una muestra reproducible de 200 000 filas, la correlación de Spearman entre el ratio ofertado/estimado y su logaritmo fue prácticamente 1, al igual que entre precio y log-precio. Esta redundancia no invalida las particiones de Isolation Forest, pero puede repartir la atribución SHAP entre variables equivalentes. Por ello, las explicaciones se interpretan por familias de variables y no como un orden causal preciso de características individuales.

Se decidió conservar ambas escalas para la fase de detección porque los cortes aleatorios pueden separar comportamientos en regiones distintas y porque la transformación reduce el peso visual de las colas. La decisión se somete a una interpretación conservadora: si dos variables transmiten casi la misma información, la suma de sus contribuciones describe una familia, no dos hallazgos independientes. Para una versión productiva conviene repetir el ajuste con una variable por transformación y comparar la estabilidad de la lista.

4.3. Modelo y arquitectura

Isolation Forest fue elegido frente a Mahalanobis, Local Outlier Factor (Breunig et al., 2000) y autoencoders por cuatro razones: no necesita etiquetas, admite valores extremos sin estimar una matriz de covarianza global, escala a millones de observaciones y dispone de herramientas de explicación para árboles. Se utilizaron 200 árboles, submuestras de 256 observaciones y semillas controladas. El parámetro de contaminación se mantuvo en modo automático; el corte final se aplicó sobre el orden de los puntajes y no durante el ajuste.

En cada árbol se elige aleatoriamente una variable y un punto de corte entre sus valores observados. La longitud de trayectoria $h(x)$ cuenta cuántas particiones necesita la observación antes de quedar aislada. El puntaje normalizado se expresa como $s(x, n) = 2^{-E[h(x)]/c(n)}$, donde $c(n)$ es la longitud esperada de búsqueda para una muestra de tamaño n . En la convención empleada por la implementación, valores más bajos del puntaje transformado representan mayor atipicidad; por eso las listas se definen mediante percentiles inferiores. Esta convención se fijó en el código y se verificó con casos sintéticos para evitar inversiones de signo.

La submuestra de 256 no significa que solo se analicen 256 ofertas. Cada árbol aprende particiones con una submuestra diferente y todas las observaciones se recorren posteriormente para obtener su puntaje. Doscientos árboles reducen la variabilidad de las particiones sin convertir el ajuste en una carga desproporcionada. Estos valores siguen la formulación habitual de Isolation Forest (Liu et al., 2008, 2012); la sensibilidad a la aleatoriedad se evalúa directamente mediante cinco semillas.

La taxonomía UNSPSC define la población de comparación. El primer nivel ajusta un modelo para cada uno de los 57 segmentos y cubre todo el conjunto. El segundo ajusta 656 modelos para clases con al menos 500 observaciones, equivalentes al 94.7 % de las ofertas. Las clases pequeñas conservan únicamente el puntaje de segmento. Esta regla evita estimar distribuciones locales con soporte insuficiente sin excluir observaciones.

Cada oferta puede recibir un puntaje de segmento y otro de clase. La regla principal toma el mínimo de ambos, de modo que una señal fuerte en cualquiera de los niveles conserva la observación. Como análisis de sensibilidad se evaluaron el promedio, el máximo y el mínimo de puntajes estandarizados. El percentil 5 se adoptó como capacidad operativa de revisión y no como estimación de la prevalencia real de irregularidades.

Cuadro 4. Especificación del modelo principal

Componente	Especificación
Unidad	Oferta de un proveedor para un ítem
Referencia global	57 modelos por segmento UNSPSC
Referencia local	656 modelos de clase con al menos 500 filas
Estimadores	200 árboles por modelo
Submuestra	256 observaciones por árbol
Combinación principal	Mínimo del puntaje estandarizado de segmento y clase
Selección operativa	5 % inferior del puntaje combinado
Reproducibilidad	Semillas fijadas y artefactos de transformación versionados

Antes de combinar los niveles, los puntajes se transformaron a rangos percentilares dentro de su población. Sin esta estandarización, un modelo de segmento y otro de clase podrían producir escalas numéricas distintas y el mínimo favorecería sistemáticamente uno de ellos. La regla de mínimo prioriza sensibilidad a rareza local o amplia; el máximo exige rareza en ambos niveles y el promedio ocupa una posición intermedia. No existe una regla universalmente correcta, de modo que su impacto se reporta

como parte del resultado.

4.4. Explicabilidad, diseño de evaluación y reproducibilidad

TreeExplainer descompone el puntaje de un árbol como suma de contribuciones respecto de una expectativa de referencia (Lundberg y Lee, 2017). Para cada oferta, un valor SHAP indica cuánto desplaza una característica el puntaje del modelo, manteniendo la semántica predictiva del conjunto de árboles. La explicación es local al modelo: describe el camino matemático que produjo el puntaje, no una razón jurídica o económica de la conducta observada.

Las contribuciones se calcularon para las 108 231 ofertas persistentes entre semillas y para una muestra estratificada de ofertas normales. Luego se agregaron los valores absolutos dentro de familias predefinidas. Una tipología se asignó cuando una familia concentró la mayor parte de la contribución; las observaciones sin predominio claro se clasificaron como mixtas. El objetivo de esta reducción es producir descripciones operativas estables, como “señal de precio” o “señal temporal”, sin exponer al analista a cincuenta variables por caso.

La agregación sacrifica detalle y puede ocultar que una variable empuja el puntaje en dirección opuesta a otra de su misma familia. Por ello, una ficha de revisión debería mostrar primero la tipología y después las contribuciones individuales con sus valores originales. La tipología facilita priorización; la explicación completa conserva trazabilidad.

La evaluación comprende cuatro ejercicios:

1. Cinco ajustes completos con semillas 42, 123, 456, 789 y 2026.
2. Umbrales entre los percentiles 1 y 10 y cuatro reglas de agregación.
3. Comparación con oferente único, sobreprecio superior a 1.5 veces el estimado y presentación tardía sin competencia, además de HBOS (Goldstein y Dengel, 2012) y ECOD (Li et al., 2022)
4. Entrenamiento con 2020–2023 y aplicación del mismo umbral a 2024–2025.

HBOS y ECOD son referencias útiles precisamente porque sus supuestos difieren de Isolation Forest: el primero combina histogramas univariados bajo independencia y el segundo utiliza distribuciones empíricas de cola. El acuerdo entre ellos no se presupone. Las explicaciones se calcularon con TreeExplainer sobre las anomalías estables y una muestra estratificada de ofertas normales (Lundberg y Lee, 2017).

Las diferencias de perfil se complementaron con la correlación biserial de rangos derivada de Mann–Whitney (r_{rb}) y con la distancia de Kolmogorov–Smirnov ($KS D$).

En este caso, r_{rb} es una medida estandarizada no paramétrica del tamaño del efecto. Cuantifica la fuerza de la asociación entre la condición de la oferta (Anómala vs. Normal) y las variables continuas u ordinales en una escala de 0 a 1. Valores cercanos a cero implican un solapamiento severo en el ordenamiento de los rangos de ambos grupos.

Por otro lado, $KS D$ corresponde al estadístico D de Kolmogorov–Smirnov y mide la distancia vertical máxima entre las funciones de distribución acumulada (CDF) de los dos grupos. A diferencia de las pruebas sobre la mediana, el estadístico D evalúa desviaciones en la totalidad de la forma de la curva, permitiendo identificar cambios en la dispersión, la asimetría o el comportamiento crítico de las colas.

Con más de tres millones de filas, los valores p son casi inevitablemente pequeños; la interpretación se concentra en la magnitud del efecto. La implementación reproducible se distribuye con la entrega y su lógica se resume en el cuadro 5.

Para dos listas A y B , el índice de Jaccard se define como el tamaño de su intersección dividido por el tamaño de su unión. El valor es uno cuando las listas coinciden y cero cuando no comparten observaciones. Esta métrica es apropiada para conjuntos de igual tamaño fijados por percentil, pero no refleja cambios de posición dentro de la lista. Por eso se conserva también el puntaje continuo y se reporta la frecuencia con la que cada oferta aparece entre semillas.

La sensibilidad al umbral responde a una pregunta de capacidad: si la institución puede revisar menos o más casos, ¿cambia el perfil de la cola? La sensibilidad a la agregación responde a una pregunta de diseño: ¿la prioridad depende de exigir rareza local, amplia o ambas? La comparación algorítmica responde a una tercera pregunta: ¿qué parte del conjunto permanece cuando cambia la definición matemática de anomalía? Presentar los tres ejercicios por separado evita que un promedio esconda fuentes de inestabilidad distintas.

La evaluación temporal preservó el orden cronológico. Todas las transformaciones que requerían estimación se ajustaron con 2020–2023 y luego se aplicaron a 2024–2025. El umbral absoluto del período de entrenamiento se mantuvo fijo para medir cambio de distribución; recalculer el percentil en prueba habría forzado por construcción una tasa de 5 % y ocultado el desplazamiento. Como contraste adicional, la lista temporal se comparó con el modelo ajustado sobre el período completo.

La ejecución se dividió en extracción SQL, construcción de características, ajuste por grupos, consolidación de puntajes, explicabilidad y reportes. Cada etapa produce un artefacto persistente con llaves de oferta, versión del código, período de datos y semilla. Los modelos de clase que no cumplen el mínimo no se crean silenciosamente: se registra la razón y la observación recibe únicamente el puntaje de segmento.

Es importante mencionar que la reproducibilidad exacta depende de conservar tanto los archivos como su versión de origen. El portal de SICOP puede corregir registros históricos; una descarga posterior no necesariamente coincide exactamente con la utilizada aquí.

Cuadro 5. Lógica computacional y principales archivos reproducibles

Etapas	Lógica	Archivo principal
Base analítica	unir oferta, ítem, cartel, proveedor e institución; convertir precios a CRC; calcular competencia y ratios	<code>datos/_build_oferta_item.py</code>
Modelo principal	transformar variables, ajustar modelos por segmento y clase, combinar puntajes y aplicar percentiles	<code>IF_SICOP_v2.ipynb</code>
Explicabilidad	calcular SHAP, agrupar contribuciones y asignar tipologías dominantes	<code>IF_SICOP_shap.ipynb</code>
Contrastes	ajustar HBOS y ECOD, calcular intersecciones, reglas y validación temporal	<code>benchmark_metodos.ipynb</code>
Evidencia del informe	tamaños de efecto, correlaciones, figuras y controles agregados	<code>analisis_complementario.py</code> y <code>generar_figuras_informe.py</code>

5. Resultados

Los resultados se presentan desde la evidencia interna hacia los contrastes más exigentes. Primero se describe la lista definida por la especificación principal. Después se evalúa si esa lista persiste ante variaciones que no deberían modificar sustancialmente el fenómeno, como la semilla. Finalmente se cambia la regla de agregación, el algoritmo y el período. Una disminución del acuerdo al avanzar en esta secuencia no es contradictoria: cada ejercicio altera un componente más sustantivo de la definición de anomalía.

Las cantidades absolutas deben leerse junto con su denominador. La tasa global de 5 % está fijada por diseño, mientras que las tasas de segmento y modalidad emergen después de aplicar un umbral común al

puntaje combinado. En consecuencia, una tasa local superior a 5 % significa que ese grupo concentra más observaciones en la cola global, es es decir, no estima una mayor incidencia de irregularidad. De forma análoga, la presencia reiterada entre métodos aumenta la robustez estadística de la rareza, pero no la gravedad jurídica del caso.

5.1. Conjunto priorizado y perfil estadístico

El percentil 5 contiene 151 067 ofertas. Este número deriva del corte operativo y no constituye un hallazgo sobre prevalencia. En consecuencia, su cercanía a tasas utilizadas en otros estudios no aporta validación independiente: era una consecuencia esperable de haber fijado el umbral antes de examinar los resultados.

Cuadro 6. Resultados de Isolation Forest según el umbral del puntaje combinado

Umbral	Corte del puntaje	Ofertas	Adjudicadas (%)	Oferente único (%)
P1	-0.0742	30 214	27.1	22.2
P2	-0.0528	60 427	27.1	21.7
P3	-0.0397	90 641	27.3	22.0
P5	-0.0217	151 067	28.0	22.2
P10	0.0050	302 134	28.6	21.5

El cuadro 6 muestra que el tamaño de la lista cambia por construcción con el percentil, mientras que los dos indicadores post-hoc varían en rangos estrechos. Los conjuntos están anidados: P1 forma parte de P2 y así sucesivamente hasta P10. La estabilidad de estas proporciones no demuestra que el corte sea óptimo; indica que la descripción general no depende exclusivamente del 5 % seleccionado.

Cuadro 7. Perfil y tamaño de efecto de las ofertas priorizadas

Variable	Mediana anómala	Mediana normal	r_{rb}	KS D
Precio ofertado (CRC)	18 000	15 695	0.023	0.056
Ratio ofertado/estimado	1.000	0.908	0.244	0.269
Número de ofertas del ítem	4	4	0.005	0.099
Número de oferentes del ítem	4	4	0.005	0.100
Días entre presentación y cierre	0.637	0.457	0.164	0.131
Oferente único (proporción)	0.222	0.121	–	–

En las comparaciones continuas del cuadro 7, Mann–Whitney y Kolmogorov–Smirnov(KS D) producen $p < 10^{-16}$. Este resultado tiene poca utilidad sustantiva por el tamaño muestral. Los tamaños de efecto muestran una lectura más matizada: la diferencia de precio es pequeña, al igual que las diferencias en conteos de ofertas y oferentes, mientras que el ratio respecto al estimado presenta una separación moderada. La figura 5 confirma que las colas, más que la observación típica, explican buena parte de las diferencias visuales.

La diferencia entre media, mediana y cola es relevante para el uso del modelo. El precio mediano de ambos grupos es próximo en términos relativos y la correlación biserial de 0.023 indica una separación mínima del orden general. Por ello, no sería correcto describir la lista como un conjunto de ofertas simplemente más caras. El ratio frente al estimado alcanza $r_{rb} = 0,244$ y KS $D = 0,269$, magnitudes mayores que las restantes, pero todavía con solapamiento considerable entre distribuciones.

Los conteos de competencia comparten una mediana de cuatro. Sus valores biserials cercanos a cero muestran que el desplazamiento de rango es pequeño, aunque KS detecta diferencias en la forma

completa de la distribución. Esto es compatible con una lista que incluye una proporción mayor de extremos competitivos sin que el caso típico cambie. Los días entre presentación y cierre presentan una separación intermedia; la dirección no debe resumirse como “presentación tardía” porque la variable mide una ventana continua y su contribución interactúa con modalidad y competencia.




Figura 5. Distribuciones de variables seleccionadas para ofertas priorizadas y normales. Las escalas se presentan de acuerdo con las transformaciones empleadas en el análisis.

Las ofertas priorizadas presentan 22.2 % de oferente único, frente a 12.1 % entre las ofertas normales. Esta comparación no debe confundirse con el 31.2 % de ítems que recibió una sola oferta, porque las unidades y denominadores son diferentes. Tampoco implica que la baja competencia explique todas las alertas: el modelo utiliza combinaciones y la mayoría de las ofertas priorizadas no pertenece a un ítem de oferente único.

La diferencia equivale a 10.1 puntos porcentuales entre listas, pero el 77.8 % de las ofertas priorizadas no pertenece a la categoría de oferente único. En términos operativos, esta señal sirve para describir una fracción relevante, no para sustituir el detector. También muestra por qué una regla exclusivamente competitiva produciría una población diferente: priorizaría todos los casos con una sola oferta, incluidos muchos cuyo precio, temporalidad y contexto son comunes dentro de su segmento.

5.2. Estabilidad interna y heterogeneidad

El Jaccard medio entre las cinco semillas fue 0.741, con un rango de 0.725 a 0.759. En total, 108 231 ofertas aparecieron en las cinco listas, equivalentes al 71.6 % del conjunto definido por la semilla principal. La estabilidad es alta frente a la aleatoriedad del algoritmo, pero no perfecta; para un uso operativo conviene diferenciar el puntaje continuo, la lista de una corrida y el subconjunto persistente.




Figura 6. Número de ofertas según su frecuencia de aparición en las cinco corridas. El eje vertical es logarítmico para mostrar simultáneamente el universo nunca priorizado y los subconjuntos persistentes.

La figura 6 muestra que el restante 28.4 % de la lista principal no debe considerarse aleatorio en bloque. Incluye observaciones cercanas al umbral, cuya posición puede cambiar por pequeñas variaciones en las particiones, y observaciones que pueden repetirse en dos, tres o cuatro corridas. La frecuencia de aparición proporciona por tanto una medida ordinal adicional. En una cola con capacidad limitada, comenzar por los casos presentes en cinco corridas reduce la dependencia de una semilla particular; si la capacidad aumenta, pueden añadirse niveles de persistencia sucesivos.

Los perfiles de adjudicación y oferente único cambiaron poco entre los percentiles 1 y 10. Las reglas de agregación mostraron una concordancia menor: el Jaccard entre mínimo y máximo fue 0.479, y 97 889 ofertas pertenecieron simultáneamente a las listas producidas por mínimo, promedio y máximo. Este resultado indica que la definición de cómo combinar segmento y clase es más influyente que la semilla.

El mínimo recupera casos extremos en una de las dos referencias aunque resulten comunes en la otra. Esto puede ocurrir cuando una observación es inusual dentro de su clase pero no dentro del segmento, o a la inversa. El máximo conserva únicamente ofertas con puntajes extremos en ambos niveles y, por tanto, aplica una condición más restrictiva. El Jaccard de 0.479 cuantifica que estas nociones no son intercambiables. La intersección de 97 889 ofrece una alternativa cuando se desea reducir la exposición a esa decisión de diseño.

La distribución por mercado tampoco es uniforme. El segmento 83, correspondiente a servicios públicos, registró una tasa de 17.0 %, frente al 5 % global fijado por diseño. La Contratación Especial alcanzó 34.1 %, mientras que las 61 ofertas de Subasta Inversa Electrónica no incluyeron alertas. El último dato debe leerse con cautela por su tamaño reducido. El detalle por segmento y procedimiento se conserva en los cuadros 16 y 15 del anexo; estos desgloses sustentan la conclusión de heterogeneidad, pero no permiten atribuir causas sin revisar los expedientes.

Las tasas por procedimiento varían junto con tamaño, composición de productos y período normativo. No se ajustó un modelo causal para separar esos factores. En particular, una modalidad puede concentrar servicios cuya comparación de precio es más difícil o registros provenientes de un período con mayor cobertura. Por eso, los desgloses se consideran diagnósticos del comportamiento del sistema. Una tasa elevada activa revisión de calidad y composición antes de cualquier interpretación institucional.

Cuadro 8. Indicadores de robustez y subconjuntos para revisión

Indicador o estrategia	Resultado	Interpretación
Jaccard entre semillas	media 0.741	Rango de 0.725 a 0.759
Jaccard mínimo frente a máximo	0.479	Sensibilidad a la agregación jerárquica
Lista principal al 5 %	151 067 ofertas	Capacidad fijada sobre el puntaje combinado
Persistentes en cinco semillas	108 231 ofertas	Menor dependencia de particiones aleatorias
Comunes a mínimo, promedio y máximo	97 889 ofertas	Menor dependencia de la agregación jerárquica
Comunes a IF, HBOS y ECOD	17 526 ofertas	Rareza bajo tres definiciones algorítmicas

Los subconjuntos del cuadro 8 no forman necesariamente una cadena anidada. Una oferta común a los tres algoritmos puede no estar presente en las cinco semillas del detector principal, y viceversa. Cada criterio controla una fuente diferente de incertidumbre. La institución debería seleccionar la cola según el riesgo que desea reducir, no interpretar la fila más pequeña como una categoría automáticamente “más sospechosa”.

5.3. Explicaciones SHAP

La metodología SHAP (SHapley Additive exPlanations) es un enfoque basado en la teoría de juegos cooperativos que se utiliza para resolver el problema de la “caja negra” en modelos de Machine Learning, proporcionando explicabilidad local y global. Fundamentada en los valores de Shapley, esta técnica asigna a cada variable económica o de competencia un valor cuantitativo que representa su contribución neta (tanto en magnitud como en dirección) hacia la predicción final de riesgo de una oferta específica. La principal ventaja matemática de SHAP radica en que garantiza la propiedad de aditividad local: la suma de los impactos de todas las características individuales equivale exactamente a la diferencia entre la puntuación de anomalía calculada para esa oferta y el valor esperado promedio de todo el conjunto de datos.

SHAP agrupó las explicaciones de las 108 231 anomalías estables en familias dominantes: precio en 41.6 %, competencia en 31.8 %, temporalidad en 14.7 % y perfiles mixtos en 10.9 %. En la muestra normal, la categoría mixta fue más frecuente. La diferencia facilita describir por qué una oferta ocupa una posición extrema dentro del modelo.

Estas proporciones identifican la familia con mayor contribución en cada observación. No expresan la fracción del puntaje total atribuible a una sola variable. Por ejemplo, una alerta clasificada como precio también puede incorporar señales de competencia o de tiempo. La tipología destaca el componente predominante para facilitar la organización de los expedientes, mientras que la explicación local ofrece el detalle completo de cada caso. El porcentaje restante se debe a familias menos frecuentes y a efectos de redondeo.




Figura 7. Media del valor absoluto de SHAP para las variables principales en los modelos de segmento y clase.

Cuadro 9. Familia dominante de las explicaciones SHAP

Familia	Anomalías estables (%)	Muestra normal (%)
Precio	41.6	11.8
Competencia	31.8	39.1
Temporalidad	14.7	5.2
Procedimiento y otras	1.0	1.5
Mixta	10.9	42.4

La figura 7 presenta la contribución absoluta media de cada variable en los niveles de segmento y clase, mientras que el cuadro 9 identifica la familia con mayor contribución en cada observación. Ambos resultados describen la importancia de los predictores dentro del modelo. La inclusión simultánea de un ratio y de su transformación logarítmica distribuye la contribución entre variables casi perfectamente correlacionadas. En consecuencia, la interpretación más sólida se concentra en la importancia conjunta de las familias de precio, competencia y temporalidad. El orden relativo entre dos transformaciones de una misma señal resulta menos informativo.

La lectura conjunta de tamaños de efecto y SHAP aporta una distinción adicional. Una variable puede tener poca separación marginal entre todas las alertas y aun así ser decisiva para un subconjunto específico en interacción con otras. SHAP describe esas decisiones locales; r_{rb} y KS resumen el contraste agregado. Que el precio absoluto tenga un efecto marginal pequeño no contradice que la familia de precio sea dominante en 41.6 % de las explicaciones, porque la familia incluye razones, transformaciones y dispersión dentro del ítem.

Para la ficha de un caso, la explicación debería mostrar el valor observado, una referencia del segmento o clase y la dirección de la contribución. Mostrar solo un gráfico de importancia global sería insuficiente: ese gráfico indica qué variables utiliza el conjunto de modelos, pero no cuáles explican una oferta particular. Esta diferencia es central para que la explicabilidad apoye una revisión documental concreta.

5.4. Reglas heurísticas, algoritmos alternativos y tiempo

Las tres reglas heurísticas marcaron 794 046 ofertas, el 26.3 % del conjunto. Entre las 151 067 alertas de Isolation Forest, 81 735 coincidieron con al menos una regla. Por tanto, 46 % quedó fuera del referente heurístico. Esta diferencia muestra que el modelo produce una lista más selectiva y distinta, pero no demuestra que los casos adicionales sean mejores: sin revisión experta no es posible separar descubrimiento útil de falsos positivos.

Las reglas producen más de cinco veces el número de alertas del detector porque no comparten una restricción de capacidad equivalente. Esta diferencia impide comparar conteos como si fueran tasas de error. Su función es medir cobertura conceptual: cuántas alertas del modelo pueden explicarse inmediatamente mediante señales conocidas y cuántas requieren examinar combinaciones menos evidentes. Los 69 332 casos sin coincidencia heurística son precisamente el grupo para el que la explicación local y la revisión experta resultan más importantes.

Cuadro 10. Cobertura y coincidencia de las reglas heurísticas con Isolation Forest

Regla	Ofertas	Universo (%)	Coincidencia IF	Jaccard IF
Oferente único	383 793	12.70	33 490	0.067
Sobrepeso mayor a 1.5	458 356	15.17	59 220	0.108
Última hora sin competencia	161 904	5.36	13 307	0.044
Cualquier regla	794 046	26.28	81 735	0.095

Los tiempos del cuadro 11 son tiempos de pared registrados en las ejecuciones del proyecto sobre un equipo con 16 GB de memoria y no un benchmark controlado entre bibliotecas. La corrida principal de Isolation Forest incluye ambos niveles jerárquicos; el experimento completo, al añadir los cinco reentrenamientos de estabilidad, tomó aproximadamente 106 minutos. HBOS y ECOD se ajustaron únicamente por segmento. Los tres cubrieron 3 021 336 ofertas, pero pequeñas diferencias por empates explican que HBOS contenga dos observaciones más al corte.

La concordancia del cuadro 12 es baja. Cada algoritmo parece capturar una estructura distinta y no corresponde presentar la comparación como validación general del detector principal. La figura 8 muestra que la intersección de los tres contiene 17 526 ofertas, el 0.58 % del universo y el 11.6 % de la lista de

Cuadro 11. Resumen de los detectores ejecutados sobre el conjunto completo

Método	Especificación efectiva	Tiempo registrado	Ofertas P5
Isolation Forest	57 modelos de segmento y 656 de clase; 200 árboles; submuestra 256; contaminación automática	aprox. 23 min por corrida principal	151 067
HBOS	por segmento; n_bins=auto, alpha 0.1, contaminación 0.05, mínimo 50 observaciones	311.6 s	151 069
ECOD	por segmento; contaminación 0.05, ejecución paralela	63.3 s	151 067

Cuadro 12. Concordancia entre detectores al percentil 5

Comparación	Jaccard
Isolation Forest – HBOS	0.088
Isolation Forest – ECOD	0.217
HBOS – ECOD	0.170




Figura 8. Intersecciones entre las listas de Isolation Forest, HBOS y ECOD al percentil 5.

Isolation Forest. Ese núcleo puede utilizarse como una cola de revisión particularmente conservadora, pero su pertenencia simultánea tampoco constituye evidencia de irregularidad.

El mayor acuerdo del detector principal ocurre con ECOD ($J = 0,217$), pero aun esa intersección deja a la mayoría de cada lista fuera del conjunto común. HBOS presenta el acuerdo más bajo con Isolation Forest ($J = 0,088$), consistente con la diferencia entre agregar rareza marginal e identificar particiones multivariadas. Los valores observados desaconsejan crear un voto mayoritario sin estudiar antes los perfiles exclusivos: tal regla favorecería tipos de anomalía capturados por métodos correlacionados y descartaría señales estructuralmente distintas.

La evaluación temporal aporta una restricción adicional. El modelo entrenado en 2020–2023 marcó 10.2 % de las ofertas de 2024–2025 al mantener fijo el umbral que seleccionaba 5 % en entrenamiento. El Jaccard con la lista del modelo ajustado sobre todo el período fue 0.371. El perfil general se conservó, pero la tasa no. Esta diferencia es compatible con cambio regulatorio, expansión de cobertura, variación de mercado o una combinación de estos factores; el diseño disponible no permite separarlos.




Figura 9. Tasa anual y comparación entre entrenamiento y prueba con el umbral absoluto fijado en 2020–2023.

La figura 9 muestra que duplicar aproximadamente la tasa de selección impide trasladar un umbral absoluto sin diagnóstico. Recalcular automáticamente el percentil devolvería la tasa a 5 %, pero no respondería si el cambio corresponde a calidad de datos, composición o comportamiento. El Jaccard de 0.371 muestra además que el efecto no se limita a agregar más observaciones: cambia de manera relevante cuáles casos ocupan la cola. La evaluación temporal es, por tanto, el principal argumento empírico para establecer monitoreo y versionado.

6. Discusión

6.1. Alcance de la evidencia

Los resultados sostienen que es posible construir una lista reproducible y manejable a partir de tres millones de ofertas. La estabilidad frente a semillas respalda la consistencia del procedimiento dentro de una misma especificación. Las explicaciones por familias permiten describir las señales y el contraste con reglas muestra que el modelo no se limita a replicar oferente único o sobreprecio.

Esa evidencia no equivale a exactitud. La ausencia de etiquetas impide estimar cuántas alertas corresponden a casos justificables, errores de registro o conductas que merecen investigación. La baja concordancia entre algoritmos refuerza esta cautela: no existe una única geometría de anomalía en los datos. Isolation Forest, HBOS y ECOD priorizan observaciones distintas porque representan la rareza de manera distinta.

El estudio distingue tres afirmaciones que con frecuencia se confunden. La primera es que una observación es extrema respecto de una población definida; esa es la afirmación directamente respaldada

por el puntaje. La segunda es que el caso merece revisión antes que otros; esta depende de la estabilidad, la capacidad institucional y el costo de omisión. La tercera es que existe una irregularidad; esa requiere evidencia documental y un criterio jurídico externo. Los resultados sostienen la primera y permiten diseñar la segunda, pero no establecen la tercera.

Las comparaciones descriptivas también tienen límites. La significancia formal es esperable con millones de observaciones, mientras que varios tamaños de efecto son pequeños. El ratio ofertado/estimado muestra la separación más clara entre las variables evaluadas, pero hereda cualquier error del estimado institucional. Una observación puede ser estadísticamente extrema porque el denominador es impreciso, no porque la oferta sea improcedente.

Esta lectura modifica la interpretación de un “falso positivo”. Sin una etiqueta, no puede saberse si una alerta es falsa antes de revisarla. Después de la revisión, un caso legítimo puede seguir siendo una anomalía estadística correctamente detectada: por ejemplo, un equipo especializado con precio excepcional debido a una especificación única. Desde el punto de vista operativo, ese caso consumió capacidad sin producir una remisión, pero desde el punto de vista matemático el detector funcionó según su objetivo. La evaluación futura debe distinguir utilidad para auditoría de fidelidad a la definición estadística.

6.2. Relación con antecedentes y factores de confusión

Los resultados coinciden con la literatura en que la baja competencia y los precios relativos son señales útiles, pero muestran que ninguna de ellas domina por sí sola. Los indicadores promovidos por la OCDE y los índices de Fazekas et al. (2016); Fazekas y Kocsis (2020) mantienen valor como referencias transparentes. Sin embargo, el 46 % de alertas sin coincidencia heurística indica que una capa multivariada modifica de manera sustantiva la prioridad. La calidad de esa diferencia todavía debe ser evaluada por especialistas.

La comparación con Domingos et al. (2016) y Araújo et al. (2024) respalda la viabilidad técnica de aprendizaje no supervisado sobre compras públicas, pero también hace visible la dependencia del diseño de evaluación. En lugar de construir una etiqueta a partir de extremos, aquí se reportan estabilidad y desacuerdo. Esta opción produce conclusiones menos directas que una medida de precisión, pero evita presentar como validación independiente una regla derivada de las mismas variables.

Los resultados nacionales de Herrera Murillo et al. (2023) y el enfoque de Potin et al. (2023) señalan una dimensión ausente: relaciones repetidas entre actores. El detector actual puede encontrar una oferta rara aunque el proveedor no tenga una posición relacional inusual, y una red puede identificar concentración persistente aunque cada oferta parezca común. Una arquitectura futura que conserve ambos puntajes podría ofrecer una prioridad más rica que cualquiera de ellos por separado.

El cambio regulatorio de diciembre de 2022 coincide con cambios de nomenclatura, umbrales y obligatoriedad de uso de SICOP (Poder Legislativo de Costa Rica, 2020). La variable de régimen permite que el modelo separe parcialmente ambos períodos, pero no identifica un efecto causal de la ley. La mayor tasa fuera de muestra en 2024–2025 puede reflejar nuevas prácticas de registro o una cobertura institucional más amplia.

La taxonomía de productos reduce comparaciones absurdas, aunque no elimina la heterogeneidad dentro de una clase. Servicios especializados pueden compartir código y diferir en alcance, calidad o condiciones contractuales. El texto libre y los anexos técnicos del cartel, que podrían explicar esas diferencias, quedaron fuera del modelo. Esta omisión favorece escalabilidad a costa de contexto.

La multicolinealidad funcional entre variables y sus transformaciones es una segunda fuente de cautela. Isolation Forest puede usar cualquiera de ellas en sus cortes; SHAP distribuye posteriormente la contribución entre predictores relacionados. La agrupación temática mitiga el problema para la comunicación, pero no lo resuelve. Una extensión metodológica razonable es repetir las explicaciones

con un conjunto reducido de variables y medir la estabilidad de las familias dominantes.

También existe selección por disponibilidad. Los registros observados corresponden a procedimientos presentes en SICOP y con campos suficientes para construir una fila. Antes de la obligatoriedad, instituciones o modalidades con menor uso pueden estar subrepresentadas. Después del cambio normativo, la composición puede expandirse aunque el comportamiento subyacente no cambie. Por tanto, una comparación anual de tasas mezcla cobertura, composición y posible desplazamiento real.

La dependencia entre filas es otra amenaza. Varias ofertas comparten cartel, proveedor, institución y período. Las pruebas de Mann–Whitney y KS no modelan esa estructura y sus valores p no se interpretan como evidencia causal. Los tamaños de efecto descriptivos siguen siendo útiles para comparar distribuciones, pero un análisis explicativo requeriría errores agrupados, modelos jerárquicos o diseños cuasiexperimentales según la pregunta.

Finalmente, las modalidades administrativas no son asignadas al azar. La alta concentración de alertas en Contratación Especial puede depender del tipo de bien, reglas de registro, tamaño de muestra y período. El modelo identifica que las observaciones ocupan posiciones extremas bajo su referencia; no permite concluir que la modalidad genere anomalías. El uso de tableros comparativos debe evitar rankings simplistas entre instituciones o procedimientos.

6.3. Aplicabilidad e implicaciones para la gestión pública

El uso propuesto es una cola de priorización. Cada alerta debería incluir el puntaje, la categoría de producto, las variables que explican la señal y un enlace al expediente. Un analista podría comenzar por las 17 526 observaciones señaladas por los tres métodos, por las 108 231 estables entre semillas o por un número fijado según capacidad semanal. La elección es operativa y debe documentarse.

El modelo requiere recalibración periódica. La evidencia temporal desaconseja mantener indefinidamente un umbral absoluto aprendido en años anteriores. También se necesita monitorear cobertura, distribución de puntajes, proporción de clases con soporte suficiente y cambios normativos. Una variación abrupta debe activar diagnóstico antes de aumentar automáticamente el número de alertas.

La revisión humana no es una etapa decorativa. Sin ella no se puede estimar valor predictivo positivo ni aprender qué señales son útiles para diferentes tipos de auditoría. Un despliegue responsable debería registrar la decisión del analista y su justificación, con categorías que distingan error de datos, particularidad legítima, riesgo administrativo y caso remitido a investigación.

Cuadro 13. Controles mínimos para un uso operativo

Etapa	Control	Evidencia conservada
Ingreso	Calidad, cobertura y cambios de esquema	Reporte de carga y excepciones
Puntuación	Versión, semilla, transformaciones y umbral	Artefacto del modelo y parámetros
Priorización	Capacidad y criterio de cola	Lista fechada con denominador
Revisión	Justificación humana y documentos consultados	Resultado estructurado del analista
Seguimiento	Tasas, deriva y distribución por grupos	Informe periódico y decisión de recalibración

El cuadro 13 convierte el modelo en un proceso auditable. Una lista sin versión ni denominador no permite reconstruir por qué un caso fue priorizado. Del mismo modo, almacenar únicamente una decisión binaria de revisión desperdicia información: las categorías y la justificación del analista son necesarias para saber si el problema era un error de registro, una condición legítima o una señal con valor investigativo.

La capacidad debe expresarse en expedientes o horas, no solo en percentiles. Las 151 067 ofertas de la lista principal excederían la capacidad anual de muchos equipos. El umbral de 5 % permite comparar experimentos, pero un despliegue requiere agrupar ofertas del mismo procedimiento, eliminar duplicación de esfuerzo y estimar el tiempo medio de revisión. El puntaje continuo permite adaptar la cola sin volver a entrenar, siempre que se reporte el corte aplicado.

El valor inmediato del sistema está en ordenar, no en automatizar decisiones. Una cola explicada puede reducir el tiempo dedicado a seleccionar expedientes y ampliar la variedad de señales consideradas. También puede servir para muestreo: combinar casos extremos con controles aleatorios permite evaluar si la priorización aporta más hallazgos que una revisión no dirigida.

La herramienta puede utilizarse en tres niveles. En operación, entrega fichas de ofertas y procedimientos. En supervisión, monitorea cambios en puntajes, calidad y composición. En investigación metodológica, permite comparar hipótesis sobre mercados, períodos o familias de señales. Mezclar estos niveles produciría incentivos inadecuados; por ejemplo, usar la tasa de alertas como indicador de desempeño institucional podría motivar interpretaciones punitivas de variaciones que en realidad provienen de cobertura.

La explicabilidad es necesaria pero no suficiente para legitimidad. Una ficha entendible facilita que el analista cuestione el resultado, mientras que el registro de revisiones permite evaluar consecuencias. La gobernanza debe incluir responsable del modelo, responsable de la decisión, mecanismo de corrección de datos y periodicidad de revisión. Sin esos roles, incluso un detector estable puede convertirse en una fuente opaca de carga administrativa.

7. Conclusiones

La contratación pública costarricense puede analizarse a nivel oferta-ítem mediante un detector no supervisado que respete la heterogeneidad de los mercados. La combinación de modelos por segmento y clase evitó una referencia global dominada por diferencias de escala y cubrió las 3 021 336 ofertas disponibles.

El percentil 5 produjo una lista de 151 067 observaciones. Su principal respaldo interno es la estabilidad: 108 231 ofertas aparecieron en las cinco corridas y el Jaccard medio fue 0.741. La decisión de combinar los niveles tuvo mayor influencia que la semilla, lo que confirma que las reglas de agregación deben formar parte explícita de la especificación.

El perfil de las alertas no se reduce al precio. El ratio frente al estimado mostró el mayor tamaño de efecto entre las variables evaluadas, mientras que el precio mediano y los conteos de competencia presentaron diferencias pequeñas. SHAP permitió resumir las señales en familias de precio, competencia y temporalidad, aunque las transformaciones correlacionadas impiden atribuir importancia causal a variables individuales.

La comparación externa obliga a una conclusión prudente. El 46 % de las alertas no coincidió con reglas simples, pero no puede asumirse que esa diferencia sea descubrimiento verdadero. Los Jaccard entre algoritmos fueron bajos y el núcleo común de 17 526 ofertas representa una fracción reducida de cada lista.

En consecuencia, el aporte del trabajo es una forma reproducible de ordenar expedientes para revisión. La confirmación de irregularidades, la medición de precisión y la evaluación causal permanecen fuera de su alcance. Esta delimitación no disminuye la utilidad del modelo; define las condiciones bajo las cuales puede utilizarse sin convertir una señal estadística en una acusación.

El análisis deja cinco conclusiones generales. Primero, la población comparable es una decisión central: la jerarquía UNSPSC mejora la coherencia respecto de un modelo global, aunque no sustituye el contexto del cartel. Segundo, la estabilidad debe descomponerse; la semilla tuvo menos efecto que la agregación entre niveles. Tercero, las diferencias marginales no explican por sí solas una lista multivariada, como

muestra el pequeño efecto del precio absoluto frente a la relevancia conjunta de su familia. Cuarto, el desacuerdo entre detectores es un resultado sustantivo, no un inconveniente que deba ocultarse mediante un promedio.

Desde una perspectiva institucional, el producto más defendible no es una etiqueta, sino una ficha priorizada y versionada. Esa ficha debe conservar puntaje, población de referencia, estabilidad, explicación, fecha y resultado de la revisión. El modelo adquiere valor cuando reduce el costo de examinar el universo y genera evidencia para mejorar el proceso; pierde legitimidad si el puntaje se comunica como conclusión sobre un proveedor.

La contribución académica reside también en hacer visibles las decisiones que suelen quedar implícitas. El umbral representa capacidad, la taxonomía define comparabilidad, la regla de combinación define sensibilidad local o global y el período define la población histórica. Reportar estas elecciones permite que otros estudios reproduzcan el análisis, cuestionen sus supuestos y comparen alternativas sin atribuir las diferencias exclusivamente al nombre del algoritmo.

8. Consideraciones éticas

El principal riesgo es la interpretación acusatoria del puntaje. Una oferta extrema puede responder a errores de captura, especificaciones poco comunes, mercados pequeños o condiciones legítimas no observadas. La interfaz y los reportes deben utilizar términos como “alerta” o “caso priorizado” y evitar etiquetas de fraude. Ninguna acción sancionatoria debería derivarse del modelo sin revisión documental y debido proceso.

La cobertura desigual puede distribuir de manera asimétrica las alertas entre instituciones, sectores y períodos. Publicar clasificaciones institucionales sin ajustar esas diferencias podría generar comparaciones injustas. Antes de difundir resultados agregados se deben presentar denominadores, intervalos temporales y reglas de inclusión, además de verificar que las categorías tengan suficiente soporte.

Los datos son públicos, pero incluyen nombres de proveedores que pueden corresponder a personas físicas. La publicación académica no necesita divulgar identidades. Los archivos de análisis y las figuras deben anonimizar nombres y cédulas, limitar el detalle de casos individuales y conservar los datos identificables solo en el entorno de trabajo autorizado.

La explicabilidad reduce opacidad, pero no convierte una asociación en una causa. Una explicación SHAP indica cómo las variables desplazaron el puntaje dentro del modelo. No explica por qué ocurrió la oferta ni si su justificación jurídica o económica es válida. Comunicar esa diferencia es parte del control ético del sistema.

Finalmente, el desempeño operativo debe evaluarse también por sus efectos. Una lista demasiado amplia puede desplazar recursos sin mejorar la detección; una lista muy estrecha puede producir falsa seguridad. Conviene auditar periódicamente qué alertas fueron revisadas, qué decisiones generaron y si determinados grupos reciben una carga desproporcionada de escrutinio.

El principio de proporcionalidad requiere que la consecuencia corresponda a la calidad de la evidencia. Un puntaje puede justificar una revisión preliminar, pero no una exclusión, sanción o publicación nominativa. Si la revisión encuentra información adversa, la decisión posterior debe apoyarse en el expediente y en el marco jurídico aplicable, no en la puntuación original. El proveedor debe poder corregir errores factuales cuando estos influyan en la evaluación.

La minimización de datos también se aplica al entrenamiento. Que un campo sea público no implica que deba utilizarse. Identificadores directos, nombres y atributos sin relación con la hipótesis analítica se excluyeron del vector. Las variables de historial deben limitarse a actividad contractual y no convertirse en perfiles generales de personas. Los accesos a la base identificable, las exportaciones y los períodos de conservación necesitan controles diferenciados.

Existe además riesgo de retroalimentación. Si las alertas históricas determinan qué casos se revisan

y solo esos resultados se convierten en etiquetas, un modelo supervisado futuro aprenderá sobre una muestra seleccionada por el detector anterior. Para reducir este sesgo, la validación debe incluir controles aleatorios y casos detectados por criterios alternativos. Las etiquetas deben registrar el proceso de selección y el nivel de evidencia, no solo el resultado final.

La transparencia debe equilibrarse con la posibilidad de manipulación. Publicar objetivos, familias de variables, controles y resultados agregados favorece rendición de cuentas. Difundir umbrales operativos exactos en tiempo real podría facilitar comportamientos estratégicos. La gobernanza debe definir qué componentes son públicos, cuáles se entregan bajo auditoría y cómo se documentan cambios sin exponer innecesariamente la operación.

Cuadro 14. Riesgos éticos y medidas de mitigación

Riesgo	Consecuencia	Mitigación
Interpretación acusatoria	Daño reputacional o decisión sin sustento	Lenguaje de priorización y revisión obligatoria
Cobertura desigual	Carga asimétrica entre grupos	Denominadores, análisis por período y controles de composición
Exposición de identidad	Reidentificación innecesaria	Anonimización de entregables y acceso restringido
Retroalimentación selectiva	Etiquetas sesgadas por revisiones previas	Muestras aleatorias y registro del mecanismo de selección
Deriva no detectada	Aumento de alertas o falsa seguridad	Monitoreo y aprobación explícita de recalibraciones

9. Trabajo futuro

La prioridad es una validación con especialistas. Una muestra estratificada debería incluir casos del núcleo multi-método, anomalías estables exclusivas de Isolation Forest, casos detectados solo por reglas y controles normales. La revisión ciega permitiría estimar acuerdo entre evaluadores y construir etiquetas con categorías más informativas que fraude/no fraude.

El diseño muestral debería fijarse antes de conocer los expedientes y registrar la probabilidad de selección de cada estrato. Una primera ronda puede medir acuerdo entre al menos dos revisores y resolver discrepancias mediante adjudicación. Además del resultado sustantivo, conviene registrar tiempo de revisión, suficiencia documental y utilidad de la explicación. Así se puede evaluar no solo cuántos casos son accionables, sino cuánto cuesta encontrarlos y qué información reduce ese costo.

La segunda línea es temporal. El aumento de alertas en 2024–2025 requiere separar cambios de cobertura, efectos regulatorios y desplazamientos de mercado. Esto puede abordarse con ventanas móviles, umbrales por cohorte y pruebas explícitas de cambio de distribución. La política de recalibración debe definirse antes del despliegue.

Las pruebas de deriva deberían operar en tres niveles: entradas, puntajes y resultados de revisión. Un cambio en entradas puede anticipar un problema aunque la tasa global permanezca estable; un cambio en puntajes indica que la referencia histórica perdió representatividad; y un cambio en resultados humanos puede revelar que la señal dejó de ser útil. La recalibración debe responder al diagnóstico correspondiente y no limitarse a restaurar una tasa prefijada.

La tercera línea es relacional. La unión entre puntajes de oferta y redes proveedor–institución permitiría estudiar si una oferta atípica forma parte de patrones recurrentes de interacción. Los antecedentes de Herrera Murillo et al. (2023) y Potin et al. (2023) ofrecen una base concreta para esa integración.

La integración puede comenzar sin construir un modelo único. Es posible presentar junto a la oferta medidas de concentración y comunidad calculadas en una ventana anterior, y luego estudiar si añaden valor para los revisores. Mantener módulos separados facilita interpretar si la prioridad proviene de la transacción, de la relación o de ambas. Solo después de validar esa utilidad tendría sentido experimentar con representaciones de grafo conjuntas.

También conviene reducir variables redundantes y repetir SHAP para comprobar si las familias explicativas son estables. La incorporación controlada de información textual del cartel podría distinguir variación legítima de especificaciones, siempre que se preserve la trazabilidad de la explicación.

El análisis textual debería iniciarse con representaciones descriptivas y recuperación de documentos comparables, no con una puntuación opaca. Un analista podría consultar carteles semánticamente similares para entender si una diferencia de precio corresponde a especificaciones distintas. Si se incorporan embeddings, será necesario versionar el modelo lingüístico y evaluar sesgos asociados a vocabulario institucional y cambios de plantillas.

Por último, el sistema debería diseñarse como un proceso de aprendizaje institucional. Las decisiones de los revisores pueden alimentar una evaluación prospectiva, siempre que las etiquetas reflejen el resultado de una revisión documentada y no la mera decisión de investigar. Solo entonces sería apropiado comparar el enfoque no supervisado con modelos supervisados.

Una evaluación prospectiva puede asignar aleatoriamente, dentro de rangos comparables, casos priorizados y controles a equipos de revisión. El resultado permitiría estimar ganancia sobre una línea base de selección y ajustar la cola a la capacidad real. Esta fase requiere protocolo, resguardo de identidades y definición previa de resultados; no debe improvisarse a partir de expedientes de alto perfil.

Finalmente, queda abierta la comparación económica. Un detector más complejo solo se justifica si mejora la asignación de tiempo respecto de reglas transparentes. La medida relevante combina tasa de casos útiles, tiempo medio, valor de la explicación y costo de mantenimiento. Evaluar esos componentes convertiría la factibilidad técnica demostrada aquí en evidencia sobre efectividad institucional.

A. Anexos: resultados complementarios

Este anexo conserva desgloses secundarios por modalidad y segmento. Las decisiones metodológicas, los parámetros efectivos, los resultados principales, las explicaciones SHAP y las validaciones de robustez se presentan en el cuerpo del informe; por tanto, su comprensión no depende del material complementario.

Cuadro 15. Tasas de alerta por tipo de procedimiento

Procedimiento	Total	Alertas	Tasa (%)
Contratación Especial	33 262	11 357	34.1
Licitación Pública Nacional	81 852	17 231	21.1
Licitación Mayor	184 301	24 532	13.3
Licitación Abreviada	223 709	22 520	10.1
Licitación Menor	264 423	24 488	9.3
Contratación Directa	1 035 200	22 769	2.2
Licitación Reducida	1 050 805	18 040	1.7
Subasta Inversa Electrónica	61	0	0.0

Cuadro 16. Resultados seleccionados por segmento UNSPSC

Seg.	Descripción	Total	Alertas	Tasa (%)	Oferente único (%)
42	Equipo médico	190 003	10 892	5.7	19
30	Materiales de construcción	174 094	9 493	5.5	5
31	Suministros de fabricación	174 396	8 159	4.7	7
78	Servicios de transporte	91 872	5 579	6.1	42
83	Servicios públicos	23 337	3 978	17.0	33
55	Publicaciones y medios	56 362	5 262	9.3	15

B. Anexo: repositorio de archivos reproducibles

Los archivos utilizados para la construcción de la base analítica, el desarrollo del modelo, el análisis de explicabilidad, las pruebas de contraste y la generación de resultados complementarios se encuentran disponibles en el siguiente repositorio:

`github.com/Kado2094/AFG_MCD_SICOP`

El repositorio incluye los archivos de código, los cuadernos de análisis y un archivo `README.md` con una descripción general de la lógica computacional y de los principales componentes reproducibles del proyecto.

Referencias

- Araújo, H. R. F., Leite, P. F., Honório, J. J. C. M., Souza, I. M. L., Albuquerque, D. W. y Santos, D. F. S. (2024). Detection of anomalous proposals in governmental bidding processes: A machine learning-based approach. *Anais do XII Latin American Symposium on Digital Government*, 121–132. <https://doi.org/10.5753/wcge.2024.2888>
- Breunig, M. M., Kriegel, H.-P., Ng, R. T. y Sander, J. (2000). LOF: Identifying density-based local outliers. *Proceedings of the 2000 ACM SIGMOD International Conference on Management of Data*, 93–104. <https://doi.org/10.1145/342009.335388>
- Conti, P. L. y Naldi, M. (2008). Detection of anomalous bids in procurement auctions. *Decision Support Systems*, 46(1), 420–428. <https://doi.org/10.1016/j.dss.2008.08.002>
- Domingos, S. L., Carvalho, R. N., Carvalho, R. S. y Ramos, G. N. (2016). Identifying IT purchases anomalies in the Brazilian government procurement system using deep learning. *2016 15th IEEE International Conference on Machine Learning and Applications*, 722–727. <https://doi.org/10.1109/ICMLA.2016.0129>
- Fazekas, M., Tóth, I. J. y King, L. P. (2016). An objective corruption risk index using public procurement data. *European Journal on Criminal Policy and Research*, 22(3), 369–397. <https://doi.org/10.1007/s10610-016-9308-z>
- Fazekas, M. y Kocsis, G. (2020). Uncovering high-level corruption: Cross-national objective corruption risk indicators using public procurement data. *British Journal of Political Science*, 50(1), 155–164. <https://doi.org/10.1017/S0007123417000461>
- Goldstein, M. y Dengel, A. (2012). Histogram-based outlier score (HBOS): A fast unsupervised anomaly detection algorithm. *KI-2012: Poster and Demo Track*, 59–63.
- Herrera Murillo, D. J., Valerio-Ureña, G., Salazar Atencio, G., Asprón, J. y Álvarez Alfaro, A. (2023). Tecnologías de información para lucha anticorrupción: análisis de la contratación pública costarricense. *Revista de Administração Pública*, 57(1), e2022-0126. <https://doi.org/10.1590/0034-761220220126>
- Izquierdo, A., Pessino, C. y Vuletin, G. (Eds.). (2018). *Better spending for better lives: How Latin America and the Caribbean can do more with less*. Banco Interamericano de Desarrollo. <https://flagships.iadb.org/en/DIA2018/Better-Spending-for-Better-Lives>
- Li, Z., Zhao, Y., Hu, X., Botta, N., Ionescu, C. y Chen, G. H. (2022). ECOD: Unsupervised outlier detection using empirical cumulative distribution functions. *IEEE Transactions on Knowledge and Data Engineering*, 35(12), 12181–12193. <https://doi.org/10.1109/TKDE.2022.3159580>
- Liu, F. T., Ting, K. M. y Zhou, Z.-H. (2008). Isolation Forest. *2008 Eighth IEEE International Conference on Data Mining*, 413–422. <https://doi.org/10.1109/ICDM.2008.17>
- Liu, F. T., Ting, K. M. y Zhou, Z.-H. (2012). Isolation-based anomaly detection. *ACM Transactions on Knowledge Discovery from Data*, 6(1), 1–39. <https://doi.org/10.1145/2133360.2133363>
- Lundberg, S. M. y Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, 30, 4765–4774.
- Organización para la Cooperación y el Desarrollo Económicos. (2016). *Preventing corruption in public procurement*. OECD Publishing.

- Organización para la Cooperación y el Desarrollo Económicos. (2023). *Government at a Glance 2023: Costa Rica*. OECD Publishing. https://www.oecd.org/en/publications/government-at-a-glance-2023_c4200b14-en/costa-rica_6a22f841-en.html
- Potin, L., Figueiredo, R., Labatut, V. y Largeron, C. (2023). Pattern mining for anomaly detection in graphs: Application to fraud in public procurement. *Machine Learning and Knowledge Discovery in Databases: ECML PKDD 2023*, 69–87. https://doi.org/10.1007/978-3-031-43427-3_5
- Poder Legislativo de Costa Rica. (2020). *Ley General de Contratación Pública, Ley 9986*. La Gaceta, alcance 116.
- Radiográfica Costarricense y Ministerio de Hacienda de Costa Rica. (2025). *Portal de datos abiertos del Sistema Integrado de Compras Públicas*. <https://www.sicop.go.cr/>
- United Nations Standard Products and Services Code. (2024). *UNSPSC codeset, version 26.0801*. <https://www.unspsc.org/>
- Velasco, R. B., Carpanese, I., Interian, R., Paulo Neto, O. C. G. y Ribeiro, C. C. (2021). A decision support system for fraud detection in public procurement. *International Transactions in Operational Research*, 28(1), 27–47. <https://doi.org/10.1111/itor.12811>